

Fraud Detection System using Big Data Analytics

Báo cáo tổng hợp pipeline phát hiện giao dịch gian lận bằng EDA, preprocessing, Apache Spark và Machine Learning.


1. Dataset



Dataset gồm fraudTrain.csv và fraudTest.csv từ Kaggle. Train set có 1,296,675 giao dịch, trong đó 7,506 giao dịch là fraud. Fraud rate chỉ khoảng 0.5789%, thể hiện bài toán mất cân bằng mạnh.

total_rows	total_columns	fraud_count	non_fraud_count	fraud_rate_percent
1296675	26	7506	1289169	0.5789

2. EDA

EDA phân tích target distribution, amount, category, merchant, thời gian, vị trí địa lý và khoảng cách customer-merchant.





3. Apache Spark Processing

Spark DataFrame được dùng để tính fraud theo category, state, merchant và hour. Kết quả được xuất ra reports/tables.

category	transactions	fraud_count	fraud_rate	avg_amount	median_amount	fraud_rate_percent
shopping_net	97543	1713	0.0176	88.4241	8.44	1.7561
misc_net	63287	915	0.0145	80.8651	9.84	1.4458
grocery_pos	123638	1743	0.0141	116.961	105.11	1.4098
shopping_pos	116672	843	0.0072	79.7792	7.76	0.7225
gas_transport	131659	618	0.0047	63.4346	62.84	0.4694
misc_pos	79655	250	0.0031	62.891	13.91	0.3139
grocery_net	45452	134	0.0029	53.6701	50.92	0.2948
travel	40507	116	0.0029	111.5047	6.26	0.2864



Top merchant có tỷ lệ fraud cao:

merchant	transactions	fraud_count	fraud_rate	avg_amount	fraud_rate_percent
fraud_Kozey-Boehm	1866	48	0.0257	98.2381	2.5723
fraud_Herman, Treutel and Dickens	1300	33	0.0254	87.0619	2.5385
fraud_Kerluke-Abshire	1838	41	0.0223	98.0354	2.2307
fraud_Brown PLC	1176	26	0.0221	89.848	2.2109
fraud_Goyette Inc	1943	42	0.0216	93.9126	2.1616
fraud_Terry-Huel	1996	43	0.0215	93.2821	2.1543
fraud_Jast Ltd	1953	42	0.0215	90.3868	2.1505
fraud_Schmeler, Bashirian and Price	1968	41	0.0208	96.7184	2.0833

4. Modeling

Hai mô hình được huấn luyện: Logistic Regression và Random Forest. Training dùng sampling giữ toàn bộ fraud và lấy non-fraud theo tỷ lệ 5:1, sau đó đánh giá trên toàn bộ test set.

model	accuracy	precision	recall	f1_score	roc_auc
random_forest	0.9836	0.1802	0.9147	0.3011	0.9899
logistic_regression	0.9393	0.0451	0.7305	0.085	0.9055



5. Kết luận

Random Forest là mô hình tốt nhất trong thử nghiệm, đạt Recall khoảng 0.9147 và ROC-AUC khoảng 0.9899. Với fraud detection, Recall cao giúp giảm số giao dịch gian lận bị bỏ sót. Precision vẫn còn thấp do dữ liệu cực kỳ mất cân bằng.

6. Hướng phát triển

Có thể cải thiện bằng threshold tuning, PR-AUC, XGBoost/LightGBM, target encoding có regularization và triển khai batch scoring bằng Spark.