

Fraud Detection System using Big Data Analytics

Báo cáo tổng hợp pipeline phát hiện giao dịch gian lận bằng EDA, preprocessing, Apache Spark và Machine Learning.

1. Dataset

Dataset gồm fraudTrain.csv và fraudTest.csv từ Kaggle. Train set có 1,296,675 giao dịch, trong đó 7,506 giao dịch là fraud. Fraud rate chỉ khoảng 0.5789%, thể hiện bài toán mất cân bằng mạnh.

total_rows	total_columns	fraud_count	non_fraud_count	fraud_rate_percent
1296675	26	7506	1289169	0.5789


2. Liên hệ Big Data 5V



Volume: hơn 1.85 triệu giao dịch train + test. Velocity: giao dịch tài chính trong thực tế phát sinh liên tục và cần cảnh báo nhanh. Variety: dữ liệu gồm amount, time, location, merchant, category và hồ sơ khách hàng. Veracity: pipeline kiểm tra missing/duplicate và loại bỏ cột định danh trực tiếp. Value: mô hình hỗ trợ phát hiện fraud, giảm rủi ro tài chính và hỗ trợ ra quyết định.

Dự án bao gồm ba nhiệm vụ chính của dữ liệu lớn: Data Management, Data Modeling and Analytics, Visualization/Decision/Value.

3. EDA

EDA phân tích target distribution, amount, category, merchant, thời gian, vị trí địa lý và khoảng cách customer-merchant.





4. Apache Spark Processing

Spark DataFrame được dùng để tính fraud theo category, state, merchant và hour. Kết quả được xuất ra reports/tables.

category	transactions	fraud_count	fraud_rate	avg_amount	median_amount	fraud_rate_percent
shopping_net	97543	1713	0.0176	88.4241	8.44	1.7561
misc_net	63287	915	0.0145	80.8651	9.84	1.4458
grocery_pos	123638	1743	0.0141	116.961	105.11	1.4098
shopping_pos	116672	843	0.0072	79.7792	7.76	0.7225
gas_transport	131659	618	0.0047	63.4346	62.84	0.4694
misc_pos	79655	250	0.0031	62.891	13.91	0.3139
grocery_net	45452	134	0.0029	53.6701	50.92	0.2948
travel	40507	116	0.0029	111.5047	6.26	0.2864



Top merchant có tỷ lệ fraud cao:


merchant	transactions	fraud_count	fraud_rate	avg_amount	fraud_rate_percent
fraud_Kozey-Boehm	1866	48	0.0257	98.2381	2.5723
fraud_Herman, Treutel and Dickens	1300	33	0.0254	87.0619	2.5385
fraud_Kerluke-Abshire	1838	41	0.0223	98.0354	2.2307
fraud_Brown PLC	1176	26	0.0221	89.848	2.2109
fraud_Goyette Inc	1943	42	0.0216	93.9126	2.1616
fraud_Terry-Huel	1996	43	0.0215	93.2821	2.1543
fraud_Jast Ltd	1953	42	0.0215	90.3868	2.1505
fraud_Schmeler, Bashirian and Price	1968	41	0.0208	96.7184	2.0833

5. Modeling

Ba mô hình được huấn luyện: Logistic Regression, Random Forest và HistGradientBoosting. Training dùng sampling giữ toàn bộ fraud và lấy non-fraud theo tỷ lệ 5:1, tune threshold theo F1-score trên validation split, sau đó đánh giá trên toàn bộ test set.

model	threshold	precision	recall	f1_score	roc_auc	pr_auc
hist_gradient_boosting_tuned_f1	0.8	0.3557	0.9245	0.5137	0.9976	0.8701
hist_gradient_boosting_high_recall_0_90	0.8	0.3557	0.9245	0.5137	0.9976	0.8701
hist_gradient_boosting_default_0_50	0.5	0.1938	0.9669	0.3229	0.9976	0.8701
random_forest_default_0_50	0.5	0.1802	0.9147	0.3011	0.9899	0.7441
random_forest_tuned_f1	0.5	0.1802	0.9147	0.3011	0.9899	0.7441
random_forest_high_recall_0_90	0.5	0.1802	0.9147	0.3011	0.9899	0.7441
logistic_regression_tuned_f1	0.71	0.1577	0.6699	0.2553	0.9055	0.1189
logistic_regression_default_0_50	0.5	0.0451	0.7305	0.085	0.9055	0.1189
logistic_regression_high_recall_0_90	0.27	0.0124	0.8149	0.0243	0.9055	0.1189





6. Kết luận

HistGradientBoosting tuned F1 là mô hình tốt nhất trong thử nghiệm, đạt Accuracy khoảng 0.9932, Precision khoảng 0.3557, Recall khoảng 0.9245 và F1-score khoảng 0.5137. ROC-AUC đạt khoảng 0.9976 và PR-AUC đạt khoảng 0.8701. So với Random Forest, mô hình này cải thiện rõ rệt cả khả năng phát hiện fraud và chất lượng cảnh báo.

7. Hướng phát triển

Có thể cải thiện bằng threshold tuning, PR-AUC, XGBoost/LightGBM, target encoding có regularization và triển khai batch scoring bằng Spark.