

Triển khai hệ thống phát hiện giao dịch gian lận sử dụng phân tích dữ liệu lớn và học máy

Báo cáo cuối kỳ học phần: Kỹ thuật và công nghệ dữ liệu lớn cho Trí tuệ nhân tạo

Thông tin

Vũ Hoàng Diệu Linh
24022387

Lớp học phần
AIT3229_1

Tháng 6, 2026

Đặt vấn đề

- Thanh toán trực tuyến và giao dịch thẻ ngày càng phổ biến.
- Gian lận tài chính gây thiệt hại cho khách hàng và tổ chức tài chính.
- Dữ liệu giao dịch có khối lượng lớn, nhiều đặc trưng và phát sinh liên tục.
- Giao dịch gian lận chiếm tỷ lệ rất nhỏ, gây mất cân bằng dữ liệu nghiêm trọng.
- Cần ứng dụng Big Data và Machine Learning để hỗ trợ phát hiện gian lận hiệu quả hơn.



Bài toán

- Phân loại nhị phân: **fraud / non-fraud**
- Target: `is_fraud`
- **0**: giao dịch hợp lệ
- **1**: giao dịch gian lận
- Khó khăn: dữ liệu mất cân bằng mạnh


Dữ liệu và đánh giá

- Dataset: Credit Card Transactions Fraud Detection Dataset (Kaggle).
- Train: **1,296,675** giao dịch
- Test: **555,719** giao dịch
- Fraud rate train: **0.5789%**
- Metrics: Precision, Recall, F1-score, ROC-AUC, PR-AUC

Tổng quan dữ liệu lớn 5V

Đặc trưng	Ý nghĩa	Trong project
Volume	Dữ liệu lớn	hơn 1.8 triệu giao dịch
Velocity	Giao dịch phát sinh liên tục	cần phát hiện rủi ro nhanh
Variety	Nhiều kiểu dữ liệu	amount, time, category, merchant, customer, location
Veracity	Cần làm sạch dữ liệu	xử lý kiểu dữ liệu, loại định danh
Value	Giá trị khai thác	hỗ trợ phát hiện fraud, giảm rủi ro

Kiến trúc hệ thống




- Raw data được phân tích bằng EDA và Spark
- Spark tạo feature insights cho bước xây dựng đặc trưng

- Modeling pipeline huấn luyện và đánh giá các mô hình ML
- Output: best model, report/slide


Phân tích khám phá dữ liệu



Target distribution



Amount distribution – log scale




Fraud rate by hour

EDA:

- Fraud chiếm tỷ lệ rất nhỏ so với giao dịch hợp lệ
- Số tiền giao dịch có phân bố lệch phải
- Tỷ lệ fraud thay đổi theo giờ giao dịch
- EDA định hướng cho bước Feature Engineering

Tiền xử lý và xây dựng đặc trưng



Kỹ thuật	Tác dụng
Time features	transaction_hour, dayofweek, month, weekend_flag
Age feature	customer_age
Distance feature	customer_merchant_distance_km
One-hot encoding	category, gender, state
Frequency encoding	merchant, job, city
Scaling	chuẩn hóa đặc trưng số
Remove identifiers	bỏ cc_num, first, last, street, trans_num


Processed data: 85 cột = 84 features + 1 target

Vai trò của Apache Spark



- Spark được sử dụng để xử lý dữ liệu giao dịch quy mô lớn và thực hiện các phép tổng hợp (aggregation).
- Không sử dụng Spark để huấn luyện mô hình trực tiếp mà tập trung vào bước phân tích dữ liệu.
- Kết quả phân tích hỗ trợ khám phá dữ liệu và xây dựng đặc trưng (Feature Engineering).

Phân tích Spark	Ý nghĩa
Fraud by category	Tìm các nhóm giao dịch có tỷ lệ gian lận cao.
Fraud by state	Phân tích phân bố gian lận theo khu vực địa lý.
High-risk merchants	Phát hiện merchant có tỷ lệ fraud bất thường.
Fraud by hour	Khám phá xu hướng gian lận theo thời gian giao dịch.
Amount by target	So sánh phân bố số tiền giữa giao dịch hợp lệ và gian lận.



Quy trình huấn luyện

- Sampling 5:1 được áp dụng trên tập huấn luyện để giảm mất cân bằng giữa fraud và non-fraud.
- Các mô hình được thử nghiệm:
 - Logistic Regression
 - Random Forest
 - HistGradientBoosting
- Validation được sử dụng để lựa chọn threshold tối ưu.
- Test set được giữ nguyên và chỉ dùng cho đánh giá cuối cùng.
- Lưu lại mô hình có kết quả tốt nhất.

So sánh kết quả thực nghiệm

Model	Precision	Recall	F1	ROC-AUC	PR-AUC
Logistic Regression tuned	0.1577	0.6699	0.2553	0.9055	0.1189
Random Forest	0.1802	0.9147	0.3011	0.9899	0.7441
HistGradientBoosting tuned	0.3557	0.9245	0.5137	0.9976	0.8701


Kết quả nổi bật

HistGradientBoosting tuned đạt kết quả tốt nhất trên **F1-score (0.5137)** và **PR-AUC (0.8701)**, đồng thời duy trì Recall rất cao trên dữ liệu mất cân bằng.

Thông tin mô hình

Best model	HistGradientBoosting tuned
Threshold	0.80
Precision	0.3557
Recall	0.9245
F1-score	0.5137
PR-AUC	0.8701

- Recall 92.45% giúp phát hiện phần lớn giao dịch gian lận.
- Precision 35.57% vẫn có ý nghĩa do fraud rate gốc chỉ 0.5789%.
- PR-AUC phù hợp hơn Accuracy trong bài toán mất cân bằng dữ liệu.



Confusion Matrix của mô hình HistGradientBoosting tuned

Kết luận

- Hoàn thành pipeline Big Data kết hợp Machine Learning.
- Triển khai đầy đủ các bước: EDA, Spark Processing, Feature Engineering, Modeling và Evaluation.
- HistGradientBoosting tuned là mô hình tốt nhất.
- Recall đạt 0.9245.
- PR-AUC đạt 0.8701.

Hướng phát triển

- Thử nghiệm XGBoost, LightGBM và CatBoost.
- Hyperparameter tuning sâu hơn.
- Xây dựng batch scoring pipeline.
- Real-time fraud detection với Spark Streaming hoặc Kafka.
- Explainability bằng SHAP.
- Dashboard giám sát fraud alerts.

Cảm ơn sự chú ý của thầy cô và các bạn! Q&A